

Projeto de Pesquisa de Iniciação Científica

Análise de Algoritmos de Otimização Bioinspirados Aplicados em Separação Cega de Fontes no Contexto Não-Linear

Palavras-chave: Separação Cega de Fontes, Modelo Post-Nonlinear, Redes Neurais de base radial, Otimização por enxame de partículas

I. Resumo

No ciclo 2021-2022, estudamos o problema de separação de fontes em misturas não-lineares, particularmente o modelo Post-Nonlinear. Começamos retomando o que foi feito em [1] e observando que o algoritmo proposto apresenta alguns problemas de convergência. Sendo assim, optamos por alterar a forma de tratar o estágio não linear da mistura, aplicando dois algoritmos bio-inspirados: algoritmos genéticos e algoritmo de otimização por enxame de partículas. A partir daí, neste ano, pretendemos analisar mais a fundo principalmente o segundo algoritmo, analisando o desempenho de topologias diferentes e incluindo também as redes neurais por base radial na análise.

II. Introdução

O problema de separação cega de fontes é encontrado em uma ampla gama de aplicações, desde sistemas de comunicação, processamento de sinais biomédicos, processamento de sinais geofísicos, processamento de sinais de áudio e imagem, além de outros. O termo “cego”, vem do fato de que busca-se recuperar os sinais originais a partir do conhecimento da mistura destes sinais e do conhecimento de algumas características estatísticas destes, ou seja, nem os sinais originais, nem a forma como foram misturados, são conhecidas [2,4,5].

Em muitos contextos como por exemplo imageamento espectral, arranjo de sensores químicos, sensoriamento remoto ou sistemas biológicos, as misturas apresentam não-linearidades inerentes. Neste contexto, para alguns modelos de mistura, as técnicas de *Análise por Componentes Independentes* (ICA – *Independent Component Analysis*) [2,3,4] ainda são válidas: modelo linear quadrático, bilinear e o Post-Nonlinear.

Para continuarmos no mesmo contexto do estudo já iniciado, continuaremos abordando o problema da mistura Post-Nonlinear, mostrado na Figura 1. Neste caso, a mistura é modelada em dois estágios, sendo o primeiro linear e o segundo não linear.

No trabalho finalizado em julho de 2022, consideramos o clássico algoritmo FastICA para separar a parte linear e testamos duas possibilidades para buscar inverter a não-linearidade: um algoritmo de evolução diferencial (AED) e um algoritmo de otimização por enxame de partículas (OEP). Os dois obtiveram bons resultados, mas uma análise mais aprofundada se mostrou necessária. Sendo assim, este projeto prevê analisar mais detalhadamente estes algoritmos, incluindo a implementação do OEP com diversas topologias, e ainda incluir as redes neurais de base radial (RBF – *Radial Basis Function*) na análise.

III. Fundamentação Teórica

Conforme mostrado na Figura 1, após o processo de mistura linear, cada sinal de mistura sofre o efeito de uma função não-linear $f(\cdot)$:

$$\mathbf{x}(n) = \mathbf{f}(\mathbf{A}\mathbf{s}(n)) \quad (1)$$

onde A é a matriz de mistura, $\mathbf{s}(n) = [s_1(n) \ s_2(n) \ \dots \ s_N(n)]$ são os sinais das fontes, $\mathbf{f}(\cdot) = [f_1(n) \ f_2(n) \ \dots \ f_N(n)]$ é a função não linear inversível e monotônica e $\mathbf{x}(n) = [x_1(n) \ x_2(n) \ \dots \ x_N(n)]$ são os sinais de mistura.




Fig. 1- Sistema de mistura Post-Nonlinear

(2)

A partir dos sinais $\mathbf{x}(n)$, precisamos recuperar os sinais das fontes. Matematicamente temos:

$$\mathbf{y}(n) = \mathbf{W}\mathbf{g}(\mathbf{x}(n)) \quad (3)$$

onde $\mathbf{y}(n) = [y_1(n) \ y_2(n) \ \dots \ y_N(n)]$ são os sinais recuperados, \mathbf{W} é a matriz de separação, idealmente a inversa de A , e $\mathbf{g}(\cdot)$ é um vetor com funções não-lineares, idealmente a inversa de $\mathbf{f}(\cdot)$.

Para se estimar a matriz \mathbf{W} e o vetor de funções não lineares $\mathbf{g}(\cdot)$, um critério possível é buscar recuperar a independência entre os sinais $y_i(n)$, por exemplo através da medida de Informação Mútua. Em [6], os autores propõem um critério simplificado, baseado no cálculo da Informação mútua, que só depende das entropias marginais dos sinais:

$$C(Y) = \sum_{i=1}^N H(Y_i) - \sum_{i=1}^N H(Z_i) - \log |\det W| \quad (4)$$

onde Y_i é a variável aleatória associada a $y_i(n)$, Z_i é a variável aleatória associada a $z_i(n) = g_i(x_i(n))$ e $H(\cdot)$ é a entropia de Shannon.

A fim de conseguir separar os sinais, precisamos de uma separação em dois estágios: primeiramente um estágio que busque estimar $\mathbf{g}(\cdot)$; caso a estimativa seja próxima da inversa de $\mathbf{f}(\cdot)$, os sinais resultantes, $\mathbf{z}(n)$, serão misturas lineares e poderão ser separados utilizando-se algoritmos clássicos de ICA como o FastICA e o InfoMax [2].

Para a estimativa de $\mathbf{g}(\cdot)$ através de algoritmos bio-inspirados, é necessário definir uma função de *fitness*. Baseado no critério mostrado em (4) e no trabalho realizado em [7], a seguinte função foi utilizada, que consiste em uma aproximação de (4):

$$I(\mathbf{y}) = -\log|W| - \sum_{i=1}^n E[\sum_{k=1}^M (2k-1)p_{ik}x_i^{2k-2}] + \sum_{i=1}^n H(\mathbf{y}_i) \quad (5)$$

onde p_{ik} são os parâmetros do polinômio de ordem M usado para aproximar a não linearidade $\mathbf{g}(\cdot)$. A entropia $H(\mathbf{y}_i)$ pode ser estimada usando a expansão de Gram-Charlier, incluindo assim somente os momentos de \mathbf{y}_i , evitando a necessidade de estimar diretamente sua pdf:

$$H(\mathbf{y}_i) \approx \frac{\log(2\pi e)}{2} - \frac{(k_3^i)^2}{2 \cdot 3!} - \frac{(k_4^i)^2}{2 \cdot 4!} + \frac{3}{8}(k_3^i)^2 k_4^i + \frac{1}{16}(k_4^i)^3 \quad (6)$$

onde k_3^i é o momento de 3ª ordem de \mathbf{y}_i e k_4^i é o momento de 4ª ordem.

Usando (5) e (6), foram testados dois métodos possíveis para a estimativa de $\mathbf{g}(\cdot)$: o algoritmo de Evolução Diferencial e o algoritmo de otimização por enxame de partículas [8]. Os dois apresentaram bons desempenhos em diversos cenários de simulação. Foram testados vários valores diferentes para o número de fontes, N e várias funções não lineares $\mathbf{f}(\cdot)$.

IV. Objetivos e Metas

O objetivo deste trabalho visa aplicar algoritmos bio-inspirados e analisar seu desempenho, quando aplicado ao problema de separação cega de fontes (BSS – *Blind Source Separation*), considerando modelos de misturas não-lineares, principalmente modelos Post-Nonlinear. Este estudo já foi iniciado e portanto agora, em uma segunda etapa, pretende-se aprofundar o que começou a ser investigado, analisando-se diferentes topologias do algoritmo de otimização por enxame de partículas e também o desempenho das redes neurais de base radial aplicadas a este problema.

V. Metodologia

Para a execução das metas descritas na seção anterior, o trabalho iniciará com uma pesquisa bibliográfica detalhada, a fim de verificar resultados na literatura que abordem o uso de algoritmos bio-inspirados na resolução de problemas de misturas Post-Nonlinear (PNL).

Em seguida, buscaremos analisar o desempenho do algoritmo de otimização por enxame de partículas (OEP) já implementado. Buscaremos avaliar os valores dos parâmetros, topologia utilizada e também os cenários de simulação nos quais o algoritmo possui melhor ou pior desempenho, variando a pdf das fontes e não-linearidades consideradas. Os programas foram implementados utilizando-se Python.

Na sequência, estudaremos também a rede neural de base radial (RBF) aplicada ao problema de separação de misturas não-lineares.

VI. Cronograma

| Etapas | Mês | | | | | | | | | | | |
|-------------------------------------------------------------|-----|----|----|----|----|----|----|----|----|----|----|----|
| | 01 | 02 | 03 | 04 | 05 | 06 | 07 | 08 | 09 | 10 | 11 | 12 |
| Pesquisa bibliográfica | x | x | x | x | | | | | | | | |
| Estudo dos parâmetros do algoritmo OEP | | | x | x | x | | | | | | | |
| Implementação do OEP usando como base diferentes topologias | | | | x | x | x | | | | | | |
| Implementação da RBF | | | | | | x | x | x | | | | |
| Simulações dos métodos implementados em vários cenários | | | | | | | | x | x | x | x | x |

| | | | | | | | | | | | | | |
|----------------------------|--|--|--|--|--|--|--|--|--|--|--|---|---|
| Escrita do relatório final | | | | | | | | | | | | X | X |
|----------------------------|--|--|--|--|--|--|--|--|--|--|--|---|---|

VII. Referências

- [1] C. A. Moraes, “Novas Abordagens para Separação Cega de Fontes no Contexto Post-Nonlinear”, Tese de Mestrado, Universidade Federal do ABC, 2020
- [2] A. Hyvarinen, J. Karhunen, E. Oja, “Independent Component Analysis”, John Wiley & Sons, 2004
- [3] P. Comon, “Independent Component Analysis, a new concept?” Signal Processing, Elsevier, v. 36, n. 3, p.287-314, 1994
- [4] P. Comon, C. Jutten, “ Handbook of Blind Source Separation: Independent Component Analysis and Applications”, Academic Press, 2010.
- [5] J.M.T. Romano et al., “Unsupervised Signal Processing: channel equalization and source separation”, CRC Press, 2010
- [6] A. Taleb, C. Jutten, “Source Separation in post-nonlinear mixtures”, IEEE Trans. on Signal Processing, v.47, n. 10, p. 2807-2820, 1999
- [7] F. Rojas, C. G. Puntonet, M. Rodríguez-Álvarez, I. Rojas, R. Martín-Clemente, “Blind Source Separation in Post-Nonlinear Mixtures Using Competitive Learning, Simulated Annealing, and a Genetic Algorithm”, IEEE Transactions on Systems, Man and Cybernetics, Part C, vol. 34, nº 4, pp. 407-416, 2004.
- [8] Y. Zheng, M. Zhang, Biogeography-based Optimization: Algorithms and Applications, Springer, 2019