



Fundação Universidade Federal do ABC

Pró reitoria de pesquisa

Av. dos Estados, 5001, Santa Terezinha, Santo André/SP, CEP 09210-580

Bloco L, 3ºAndar, Fone (11) 3356-7617

iniciacao@ufabc.edu.br

Projeto de Iniciação Científica submetido
para avaliação no Edital: 04/2022

Título do projeto: Previsão de Curva de Irradiância Solar para utilização no Gerenciamento Energético de Microrredes.

Palavras-chave do projeto: Irradiância Solar; Previsão de curvas de Irradiância; Redes Neurais; Geração Fotovoltaica; Microrrede

Área do conhecimento do projeto: Geração de Energia Elétrica

Sumário

1 Resumo	2
2 Introdução e Justificativa	2
3 Objetivos	4
4 Metodologia.....	4
4.1 Técnicas a serem exploradas.....	4
4.2 Ferramentas Computacionais e Informações a serem utilizadas	6
5 Viabilidade	7
6 Cronograma de atividades	7
Referências.....	8

1 Resumo

As microrredes agregam recursos energéticos distribuídos, a fim de um melhor aproveitamento das fontes intermitentes para suprir as demandas locais e fornecer serviços às concessionárias de energia elétrica. No entanto, para realizar tal aproveitamento e fornecimento de serviços, torna-se necessário uma previsão da geração intermitente para o gerenciamento energético local das microrredes. Nos últimos anos, a geração de energia solar fotovoltaica tem crescido nas zonas urbanas do Brasil. Tal geração, em consumidores conectados nas redes de média tensão, pode formar microrredes que têm a possibilidade de oferecer serviços para a operação do dia seguinte das redes elétricas de distribuição. Com o intuito de melhorar a previsão de geração para os estudos de gerenciamento energético de microrredes com sistemas fotovoltaicos, nesta pesquisa se desenvolverá um método de previsão de curva de irradiância solar para a operação do próximo dia. Para mostrar as vantagens do método proposto, a proposta será aplicada utilizando dados da usina solar instalada na Universidade Federal do ABC (UFABC), campus Santo André, e dos dados meteorológicos coletados nas estações meteorológicas do Serviço Municipal de Saneamento Ambiental de Santo André (SEMASA). Os resultados deste projeto podem ajudar nos estudos de gerenciamento de microrredes com sistemas fotovoltaicos e na sua implementação nas áreas de concessão das empresas distribuidoras de energia elétrica.

2 Introdução e Justificativa

No Brasil, o Conselho Nacional de Política Energética define microrrede como a integração de recursos de geração distribuída, armazenamento de energia elétrica e cargas em sistema de distribuição secundário. Além disso, este órgão menciona que a operação das microrredes pode ser isolada ou conectada à rede de distribuição, de modo que possa auxiliar as concessionárias de energia elétrica na melhora da qualidade do fornecimento da energia (Brasil, 2022). Assim, a diminuição das perdas elétricas, a recomposição e o autorrestabelecimento da energia elétrica através das microrredes tem chamado a atenção de diversas concessionárias brasileiras.

No ano de 2021 a Companhia Paranaense de Energia solicitou permissão de compra de energia elétrica produzida a partir de microrredes à Agência Nacional de Energia Elétrica

(ANEEL). O objetivo dessa compra é melhorar os índices de continuidade no fornecimento de energia (DEC-FEC), sendo necessário que a geração distribuída na microrrede tenha uma potência instalada entre 1 a 30 MW. Adicionalmente, tal geração deve ter uma operação contínua de injeção de 5 horas de geração (COPEL, 2020).

A venda direta de energia das microrredes para as concessionárias de distribuição devem seguir as regulamentações estabelecidas pela ANEEL. Os documentos para essa regulação se encontram nos Procedimentos de Distribuição de Energia Elétrica (PRODIST), sendo divididos em 11 módulos. Os Módulos 3 e 8 contêm detalhes quanto à conexão de elementos na rede de distribuição e quanto ao controle do fornecimento de energia, respectivamente (PRODIST, 2016).

Para garantir controle de fornecimento de energia especificado no Módulo 8 do PRODIST, as microrredes operam com softwares de sistemas de gerenciamento de energia (*Energy Management System*, EMS) (ZIAA et al, 2018). Esses sistemas de gerenciamento são responsáveis por controlar cada sistema energético que faz parte da microrrede, como: geração, armazenamento e cargas com alto consumo. A evolução dos sistemas EMS são nomeados de sistemas inteligentes de gerenciamento de energia distribuída (*Distributed Intelligent Energy Management System*, DIEMS). Os DIEMS são usados para a redução dos custos operacionais a partir da otimização do fluxo de potência, utilizando previsões da demanda e da geração (CHAKRABORTY; WEISS; SIMOES, 2007).

A informação de previsão de potência injetada pela fonte geradora é uma das entradas do software EMS/DIEMS. Essa entrada é indispensável para o fluxo de potência adequado, sendo a informação base para o planejamento energético da microrrede (CHAKRABORTY; WEISS; SIMOES, 2007). No caso de microrredes com sistemas fotovoltaicos em zonas urbanas, como a microrrede a ser analisada nesta pesquisa, se tem uma base de dados históricos reduzida para a realizar a previsão da curva de irradiância solar. (POMBO et al, 2022).

A geração de energia da fonte solar fotovoltaica está atrelada aos níveis de irradiância solar e a variáveis climáticas (temperatura, quantidade de nuvens, etc.). Um dos maiores problemas da previsão da curva de irradiância é a variabilidade das informações dada sua dependência de fatores meteorológicos (POMBO et al, 2022). Essa variabilidade está presente, inclusive, dentro da região da pesquisa da cidade de Santo André localizada na região do ABC Paulista, possuindo regiões de “micro-climas” específicos dentro da própria cidade. Além disso, é importante considerar pontos referentes à instalação dos painéis e sua localização no tratamento dos resultados da previsão como nível de sombreamento, ângulo de instalação, etc. (VIAN et al, 2021).

Na literatura especializada, encontram-se diversas técnicas para realizar a previsão da curva de irradiância para microrredes, podendo ser classificadas em: (i) físicas, que utilizam de modelos matemáticos bem definidos para a descrição do comportamento da irradiância (MAYER, 2021); (ii) estatísticas que se utilizam apenas do histórico de dados e projetam a frente por meio de auto-regressores como ARMA, ARIMA e suas derivações (SIAMI-NAMINI, 2019); (iii) inteligência artificial (IA) que tem como foco a utilização de técnicas de regressão por meio de árvores de decisão, redes neurais e suas derivações e (iv) híbridas, combinação das anteriores, principalmente as de IA (WAN et al, 2015).

Nos últimos anos, diversos métodos de previsão de curva de irradiância têm sido apresentados. A previsão de irradiância em microrredes remotas é tratado por SHAKYA (2016), a partir de regressões lineares considerando condições de céu diferentes. Já a utilização de

modelos híbridos de duas redes neurais, CNN (*Convolutional Neural Networks*) e LSTM (*Long-Short Term Memory*) é desenvolvido por ZANG (2020). Outra abordagem é a previsão da curva de irradiância realizada por ZAMBRANO (2020) para locais onde não há uma quantidade significativa de dados para realizar a previsão e o autor realiza uma *clusterização* (agrupamento) por meio de outros locais com características geográficas e meteorológicas próximas.

A proposta desta pesquisa, fundamenta-se na aplicação de um modelo híbrido composto por uma rede neural artificial, ANN (*Artificial Neural Networks*), um algoritmo de *clusterização*, KNN (*K-Nearest Neighbors*), e uma rede neural recorrente, RNN (*Recurrent Neural Networks*).

A variação de ANN a ser utilizada é denominada como mapeamento auto organizável, SOM (*Self-Organizing Map*), também conhecida como mapa de Kohonen, seu criador. A SOM é indicada para o mapeamento das variáveis identificando quais são as de maior importância. O algoritmo de *clusterização* KNN tem o objetivo de indicar qual será o tipo de cenário de irradiância mais propício para o dia seguinte de operação com base nos grupos selecionados para cada um dos últimos 5 dias de operação. Depois da definição do cenário mais propício, outra variante de RNN será utilizada como preditor da irradiância, com o algoritmo LSTM.

Na aplicação da proposta, considera-se que o horizonte de previsão da curva de irradiância é de um dia à frente (D+1, curto) e utiliza os dados meteorológicos disponibilizados pelas estações meteorológicas do Serviço Municipal de Saneamento Ambiental de Santo André (SEMASA) e da usina solar da Universidade Federal do ABC (UFABC). Um caso de estudo da previsão da curva de irradiância solar será realizado na microrrede do campus de Santo André da UFABC, mensurando os ganhos no planejamento da microrrede e verificando as variáveis que mais impactam a previsão da curva de irradiância para diferentes regiões da cidade.

3 Objetivos

O principal objetivo da pesquisa consiste em:

- Desenvolver um método de previsão para a curva de irradiância solar, que possa auxiliar no gerenciamento energético de microrredes da operação do dia seguinte.

Para se alcançar o objetivo principal, devem ser concluídos os objetivos específicos listados abaixo:

- Identificar padrões de tendência e de sazonalidade relacionados à irradiância solar ao longo do tempo;
- Estudar correlação entre a irradiância e fatores ambientais;
- Identificar as variáveis climáticas que mais impactam a previsão da curva de irradiância e seus efeitos em diferentes regiões de obtenção dos dados;
- Contribuir para otimização do planejamento da implementação de uma microrrede da UFABC;

4 Metodologia

4.1 Técnicas a serem exploradas

Os trabalhos mais recentes que envolvem a predição de irradiância utilizam diversos métodos, desde de regressões lineares a modelos híbridos. Alguns autores utilizaram regressões

lineares e decomposição de Fourier para predição de irradiância a partir de histórico e condições do céu (SHAKYA, 2017). Outros calcularam a irradiância externa prevista a partir de variáveis climáticas com técnica de *machine learning* (FJELKESTAM, 2022).

Algoritmos de ANN foram utilizados para identificar padrões nas variáveis climáticas e da irradiância solar em estações meteorológicas e realizar projeções em lugares que não possuem a possibilidade de medição, considerando a distância de Mahalanobis ponderada (ZAMBRANO, 2020).

Além dos métodos puramente regressivos, os estudos abordaram parte de técnicas probabilísticas envolvendo criação de cenários possíveis utilizando EPS (*Ensemble Prediction Systems*) (LE GAL LA SALLE et al, 2020).

Outros estudos de previsão da curva de irradiância utilizam modelos híbridos, constituídos por redes neurais com o objetivo de segregar inicialmente as informações brutas em conjuntos separáveis e posteriormente a aplicação da previsão em horizontes de tempos diferentes (ZANG et al, 2020; YANG et al, 2014).

A proposta nesta pesquisa é o desenvolvimento de uma técnica de previsão híbrida utilizando ANN, aprendizado não supervisionado para clusterização, e RNN para séries temporais como o algoritmo de LSTM.

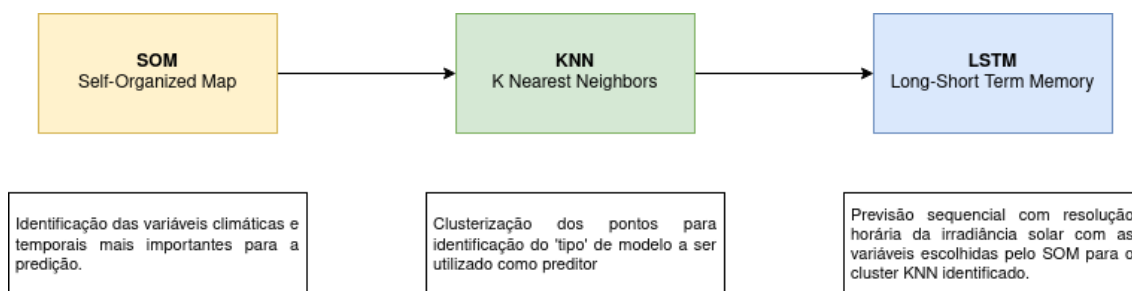


Figura 1 - Técnicas utilizadas na metodologia

Na primeira etapa, um algoritmo será desenvolvido para identificação das variáveis mais representativas, ordenando as de maior impacto na predição da irradiância solar. Nesse algoritmo, utiliza-se a técnica de mapeamento SOM ou mapa de Kohonen (MILJKOVIC, 2017).

Após determinar as variáveis mais representativas na base de dados a ser disponibilizada nessa pesquisa, se definirá o dia do ano e a média das medidas climáticas passadas (para o horizonte de estudo).

Na segunda etapa utiliza-se o KNN, algoritmo de aprendizado não supervisionado para *clusterização* dos dados, a fim de identificar grupos que compartilhem semelhanças. Depois da *clusterização* dos dados, nesta etapa se verificará se os 5 últimos dias estão agrupados no mesmo grupo ou se há alguma mudança de grupos indicando uma variação no clima. Com o agrupamento concluído pelo KNN, espera-se reduzir impactos pertinentes a mudanças atmosféricas repentinas, identificando tendência ou variabilidade para o próximo dia.

Na última etapa, a rede neural LSTM será responsável pela previsão da irradiância de vários passos adiante, com resolução de uma hora. O grande diferencial dessa rede é a sua aplicabilidade em séries temporais para a previsão de eventos sequenciais (HOCHREITER, 1997).

Embora os algoritmos SOM e LSTM já tenham sido utilizados anteriormente de forma segregada, a proposta indica o acoplamento de ambos em um modelo híbrido. Salienta-se que a *clusterização* por meio do KNN é totalmente nova para os estudos de previsão da curva de irradiância, podendo caracterizar possíveis variações por causa de fatores climáticos.

4.2 Ferramentas Computacionais e Informações a serem utilizadas

O ambiente de desenvolvimento do método de previsão será linguagem de programação *Python* que é *open source* e multi paradigma. Tal linguagem foi escolhida por ter uma comunidade ampla de pesquisadores no desenvolvimento de inteligência artificial.

As principais bibliotecas a serem utilizadas são: *pandas* e *numpy* para o processamento e tratamento dos dados; *statsmodels* para análise estatística dos dados; *scikitlearn*, *sklearn* e *tensorflow* para os algoritmos de regressão baseados em IA; e *seaborn* para visualização das séries temporais e correlações entre as variáveis. Vale ressaltar que podem aparecer outras ao longo do projeto.

Os dados a serem utilizados para a geração do modelo são coletados por meio das cinco estações meteorológicas do SEMASA espalhados na cidade de Santo André e pela usina solar fotovoltaica do Projeto Solar da UFABC. Depois da coleta, são processados pelo Laboratório de Integração de Sistemas Ambientais e Urbanos – ISAU-seco e então disponibilizados no banco de dados climatológicos. A Tabela 1 indica a localização de cada uma das estações de onde serão coletadas as informações para a previsão:

Tabela 1 - Localização das estações meteorológicas do SEMASA

Estação	Endereço	Latitude	Longitude	Altitude
Camilópolis	Rua Olegário Mariano, n. 218 Jardim Utinga, Santo André – SP	-23.622°	-46.521°	814 m
Erasm Assunção	Rua Miguel Guillen, n. 297 Jardim Rina, Santo André - SP	-23.647°	-46.494°	810 m
Tanque de Detenção	Rua Grã Bretanha, Piscinão Rm9, Santo André – SP	-23.664°	-46.552°	751 m
Paraíso	Rua Osvaldo Cruz n. 99, Paraíso, Santo André - SP	-23.679°	-46.533°	823 m
Vila Vitória	Rua Batuíra n. 59, Vila Vitoria, Santo André – SP	-23.686°	-46.512°	813 m

As variáveis a serem consideradas nesta pesquisa são: irradiância solar, temperatura, umidade relativa, precipitação, pressão atmosférica, velocidade e direção do vento. A disponibilidade dos dados no banco de dados ocorre a cada hora, com resolução das medições a cada 15 minutos.

5 Viabilidade

O estudo proposto demanda apenas das ferramentas computacionais listadas na Seção 4.2 e se utilizará de um computador pessoal, acesso à internet e acesso aos dados disponibilizados pelo SEMASA e pela usina solar fotovoltaica da UFABC, campus Santo André.

O presente estudo faz parte do Projeto Solar UFABC, em parceria com a concessionária de energia ENEL, com o objetivo de conduzir estudos de eficiência energética e minigeração de energia elétrica em instituições públicas de educação superior. O projeto faz parte da chamada pública 001/2016 da ANEEL para projetos de eficiência energética (PEE) e de pesquisa e desenvolvimento (P&D) de 2016.

6 Cronograma de atividades

Abaixo são descritas as atividades desempenhadas e o cronograma das mesmas:

1. Pesquisa
 - a. Leitura das principais técnicas utilizadas; e
 - b. Escolha da técnica utilizada.
2. Dados
 - a. Coleta;
 - i. Dados Meteorológicos das unidades do SEMASA de Santo André;
 - ii. Dados Meteorológicos do Projeto Solar da UFABC.
 - b. Disponibilização em resolução apropriada; e
 - c. Tratamento.
 - i. Padronização;
 - ii. Normalização; e
 - iii. Estudos estatísticos (boxplot, outliers, tendência, sazonalidade)
3. Técnica empregada
 - a. Criação das Variáveis;
 - b. Escolha dos períodos de treino, teste e validação;
 - c. Treinamento do modelo; e
 - d. Tunelamento de hiper parâmetros
4. Testes da Aplicação
 - a. Forecast por um período de tempo; e
 - b. Análise da efetividade da solução

Tabela 2 – Cronograma de atividades previstas

Etapa	2022								2023			
	mai	jun	jul	ago	set	out	nov	dez	jan	fev	mar	abr
1.a												
1.b												
2.a												
2.b												
2.c												
3.a												
3.b												
3.c												
3.d												
4.a												
4.b												

Referências

AGÊNCIA ESTADUAL DE NOTÍCIAS. *COPEL VAI OPERAR MICRORREDES COM GERAÇÃO DISTRIBUÍDA*. Agência Estadual de Notícias [online], Paraná, 17 set. 2020. Energia. Disponível em: <<https://www.aen.pr.gov.br/Noticia/Copel-vai-operar-microrredes-com-geracao-distribuida>>. Acesso em 05 jun. 2022.

AGÊNCIA NACIONAL DE ENERGIA ELÉTRICA (ANEEL); *Geração Distribuída*. 2022. Disponível em: <<https://www.gov.br/aneel/pt-br/assuntos/geracao-distribuida>> Acesso em 28 de maio de 2022.

AGÊNCIA NACIONAL DE ENERGIA ELÉTRICA (ANEEL); *Micro e minigeração distribuída: sistema de compensação de energia elétrica*. 2016. Folheto. (31 p.), il. (Cadernos temáticos ANEEL). Disponível em: <<https://biblioteca.aneel.gov.br/acervo/detalhe/223874>> Acesso em 29 de maio de 2022.

AGÊNCIA NACIONAL DE ENERGIA ELÉTRICA (ANEEL); *Procedimentos de Distribuição de Energia Elétrica no Sistema Elétrico Nacional – PRODIST*. 2016. Disponível em: <<https://antigo.aneel.gov.br/prodist>> Acesso em 29 de maio de 2022.

BRASIL. Lei nº 14.300, de 6 de janeiro de 2022. *Institui o marco legal da microgeração e minigeração distribuída, o Sistema de Compensação de Energia Elétrica (SCEE) e o Programa de Energia Renovável Social (PERS)*. Brasília, DF. Disponível em: <https://www.planalto.gov.br/ccivil_03/_ato2019-2022/2022/lei/l14300.htm>. Acesso em 8 de junho de 2022.

CHAKRABORTY, S.; WEISS, D.; SIMOES, M. G. *Distributed Intelligent Energy Management System for a Single-Phase High-Frequency AC Microgrid*. Vol. 54, nº 1. 2007. Disponível em: <https://www.researchgate.net/publication/3218831_Distributed_Intelligent_Energy_Manage>

ment_System_for_a_Single-Phase_High-Frequency_AC_Microgrid>. Acesso em 8 de junho de 2022.

COMPANHIA PARANAENSE DE ENERGIA (COPEL). *Copel contratará energia de geração distribuída para operar microrredes*. 2020. Disponível em: <<https://www.copel.com/site/copel-contratar-energia-de-geracao-distribuida-para-operar-microrredes/>> Acesso em 11 de junho de 2022.

EMPRESA DE PESQUISA ENERGÉTICA (EPE); *Balanço Energético Nacional*. 2021. Disponível em: <<https://www.epe.gov.br/sites-pt/publicacoes-dados-abertos/publicacoes/PublicacoesArquivos/publicacao-601/topico-596/BEN2021.pdf>> Acesso em 28 de maio de 2022.

FJELKESTAM, C. A. F., CAI, Z. Novel machine learning approach for solar photovoltaic energy output forecast using extra-terrestrial solar irradiance. *Applied Energy*, v. 306, 2022. Disponível em: < <https://doi.org/10.1016/j.apenergy.2021.118152>> Acesso em 17 de maio de 2022.

HOCHREITER, S. SCHMIDHUBER, J. Long Short-Term Memory. *Neural Computation*, v. 9, n 8, p. 1735–1780, nov. 1997. Disponível em: < <https://dl.acm.org/doi/10.1162/neco.1997.9.8.1735>>. Acesso em: 10 de Junho de 2022.

INSTITUTO PARA O DESENVOLVIMENTO DE ENERGIAS ALTERNATIVAS NA AMÉRICA LATINA (IDEAL); *Guia de Microgeradores Fotovoltaicos*. 2013. Disponível em: < <http://www.americadosol.org/guiaFV/>> Acesso em 28 de maio de 2022.

LASSETER, R. H. MicroGrids. *IEEE Power Engineering Society Winter Meeting*. Nova York, v. 1, n. 1, p. 305-308, 27-31 jan. 2002. Disponível em: <<https://ieeexplore.ieee.org/document/985003>>. Acesso em 11 de junho de 2022.

LE GAL LA SALLE, J. BADOSA, J. DAVID, M. PINSON, P. LAURET, P. Added-value of ensemble prediction system on the quality of solar irradiance probabilistic forecasts. *Renewable Energy*. v. 162, p. 1321-1339, dez. 2020. Disponível em < <https://doi.org/10.1016/j.renene.2020.07.042>>. Acesso em: 19 de maio de 2022.

MAYER, M. J., & Gróf, G. Extensive comparison of physical models for photovoltaic power forecasting. *Applied Energy*. V. 283, fev. 2021. Disponível em < <https://doi.org/10.1016/j.apenergy.2020.116239>>. Acesso em: 19 de maio de 2022.

MILJKOVIC, D. Brief review of self-organizing maps. In: 40th INTERNATIONAL CONVENTION ON INFORMATION AND COMMUNICATION TECHNOLOGY, ELECTRONICS AND MICROELECTRONICS, MIPRO, 22-26 mai. 2017. Croácia. *Proceedings*, Nova York: IEEE, 2017, p. 1061-1066. Disponível em < <https://doi.org/10.23919/MIPRO.2017.7973581>>. Acesso em: 20 de maio de 2022.

POMBO, D. V. BACHER, P. ZIRAS, C. BINDNER, H. W. SPATARU, S. V. & SØRENSEN, P. E. Benchmarking physics-informed machine learning-based short term PV-power forecasting tools. *Energy Reports*, v. 8, p. 6512–6520, nov. 2022. Disponível em < <https://doi.org/10.1016/j.egyr.2022.05.006>>. Acesso em: 21 de maio de 2022

SHAKYA, A. et al. Solar Irradiance Forecasting in Remote Microgrids Using Markov Switching Model. *IEEE Transactions on Sustainable Energy*. Nova York, v. 8, n° 3, p. 895-905, jul. 2017. Disponível em: <<https://ieeexplore.ieee.org/document/7745906>>. Acesso em 1 de março de 2022.

SIAMI-NAMINI, S. TAVAKOLI, N., & SIAMI N. A. A Comparison of ARIMA and LSTM in Forecasting Time Series. I: 17TH IEEE INTERNATIONAL CONFERENCE ON MACHINE LEARNING AND APPLICATIONS, 17-20 dez. 2018. Estados Unidos da América. *Proceedings*, Nova York: IEEE, 2019, 1394–1401. Disponível em < <https://doi.org/10.1109/ICMLA.2018.00227> >. Acesso em: 18 de maio de 2022.

VIAN, Ângelo. TAHAN, Carlos Marcio Vieira. AGUILAR, Guido Javier Rostegui. GOUVEA, Marcos Roberto. GEMIGNANI, Matheus Mingatos Fernandes. *Energia Solar Fundamentos Tecnologia e Aplicações*. São Paulo, Editora Blucher, 2021. Disponível em: Disponível em < <https://integrada.minhabiblioteca.com.br/#/books/9786555500592/> >. Acesso em 18 junho 2022.

WAN, C.; ZHAO J.; SONG Y.; XU, Z.; LIN, J. e HU, Z. Photovoltaic and solar power forecasting for smart grid energy management. *CSEE Journal of Power Energy and Systems*, v. 1, n. 4, p. 38–46, dez. 2015. Disponível em: <<https://ieeexplore.ieee.org/document/7377167>>. Acesso em 28 de maio de 2022.

YANG, H. T. HUANG, C. M. HUANG, Y. C. PAI, Y. S. A weather-based hybrid method for 1-day ahead hourly forecasting of PV power output. *IEEE Transactions on Sustainable Energy*, v. 5, n. 3, p. 917-926, abr. 2014. Disponível em: < <https://doi.org/10.1109/TSTE.2014.2313600> >. Acesso em 16 de maio de 2022.

ZAMBRANO Andres F. GIRALDO, Luis F. Solar irradiance forecasting models without on-site training measurements. *Renewable Energy*, v. 152, n. 1, p. 557-566, jun. 2020. Disponível em: < <https://doi.org/10.1016/j.renene.2020.01.092> >. Acesso em 30 de maio de 2022.

ZANG H. LIU L. SUN L. CHENG L. WEI Z. SUN G. Short-term global horizontal irradiance forecasting based on a hybrid CNN-LSTM model with spatiotemporal correlations. *Renewable Energy*, v. 160, n. 1, p. 26-41, nov. 2020. Disponível em: < <https://doi.org/10.1016/j.renene.2020.05.150> >. Acesso em 28 de maio de 2022.

ZIAA, M. F. ELBOUNCHIKHIB, E. BENBOUZIDA, M. Microgrids Energy Management Systems: A Critical Review on Methods, Solutions, and Prospects. *Applied Energy*, v. 222, n. 1, p 1033-1055, jul. 2018. Disponível em <<https://www.sciencedirect.com/science/article/abs/pii/S0306261918306676>> Acesso em 29 de maio de 2022.