



Fundação Universidade Federal do ABC

Pró-reitoria de pesquisa

Av. dos Estados, 5001, Santa Terezinha, Santo André/SP, CEP 09210-580

Bloco L, 3º Andar, Fone (11) 3356-7617

iniciacao@ufabc.edu.br

Projeto de iniciação científica

Título do projeto: Métodos de data augmentation de EMG de alta densidade para uso na classificação de movimento

Palavras-chave do projeto: Aprendizagem de máquinas; Dados abertos; Computação científica

Área do conhecimento do projeto: Engenharia Biomédica

Bolsista: Sim

Santo André- SP

2022

Resumo

O uso crescente do EMG de alta densidade possibilitou o uso desse tipo de sinal para a classificação de movimento. No entanto, os métodos utilizados para isso requerem uma quantidade de dados muito maior do que o praticável para dados de origem biomédica. Uma das opções para contornar essa limitação é a utilização de métodos de data augmentation, para gerar dados artificiais a partir dos dados reais para serem utilizados na fase de treinamento das redes neurais. Esse trabalho irá estudar diferentes métodos de Data augmentation para a classificação do movimento. Por fim, os códigos computacionais e resultados serão disponibilizados ao público na plataforma Github.

Introdução

A maioria das atividades diárias são realizadas com a mão, como pegar objetos, digitar e escrever. O fato de serem diferentes músculos que controlam os dedos da mão permite que a pessoa realize movimentos envolvendo um ou todos os dedos. Porém, isso traz uma complexidade na forma com que se controla os movimentos, envolvendo os sistemas biomecânicos e neurais (Farina et al. 2004, 2008 e Keenan et al. 2006a, 2006b).

Nas últimas décadas, o uso da eletromiografia (EMG) teve uma grande importância no estudo do controle motor e biomecânica (Jesinger; Stonick, 2017). No entanto, como o EMG de superfície é uma medida única do músculo, existem muitas limitações no seu uso (Farina et al. 2004, 2008 e Keenan et al. 2006a, 2006b).

Nos últimos anos, os avanços tecnológicos permitiram a criação de *arrays* de alta densidade de eletrodos de EMG (HD-EMG), com dezenas, ou mesmo mais de uma centena, de eletrodos (Merletti et al. 2009). O uso de HD-EMG elimina boa parte das limitações do EMG

de superfície convencional e permite, entre outras coisas, a sua utilização para classificação de movimentos.

A classificação de movimentos consiste em estimar qual o movimento que está sendo realizado por um sujeito saudável, a partir dos sinais elétricos musculares captados. As tentativas de solucionar o problema envolvem formular métodos computacionais, em geral, métodos de aprendizagem de máquina, para classificar qual a tarefa motora realizada pelo sujeito, tendo como informação o EMG de alta densidade de músculos envolvidos naquela tarefa motora. Realizar corretamente essa identificação é interessante para, entre outros fins, utilizar em próteses para deficientes físicos que identifiquem o movimento desejado pelo usuário de forma automática (Farina et al. 2017).

As tentativas mais recentes de fazer essa classificação têm usado, em sua maioria, redes neurais convencionais e alguns trabalhos utilizam redes neurais convolucionais. No entanto, os trabalhos ainda conseguem identificar apenas alguns poucos tipos de movimentos (Xiong et al. 2021). É interessante notar que os métodos para identificar o movimento a partir do EMG de superfície podem ser usados para outros fins, por exemplo, para identificar doenças motoras a partir do EMG de alta densidade (Phinyomark; Scheme, 2018).

Uma grande limitação para o sucesso da classificação de movimento a partir do HD-EMG é a quantidade de amostras de um mesmo conjunto de dados. Os dados existentes contém em torno de algumas dezenas de sujeitos. A baixa quantidade de dados dificulta a aprendizagem dos modelos de aprendizagem de máquinas.

Uma forma de contornar essa limitação é com o uso de métodos conhecidos como data augmentation. Esses métodos consistem em criar de forma artificial dados para serem usados na fase de treinamento dos modelos usados na classificação do movimento. Com isso, o

objetivo desse trabalho é explorar diferentes métodos de Data Augmentation no uso da classificação do movimento.

Objetivos

Explorar diferentes métodos de Data Augmentation no uso da classificação do movimento a partir do EMG de alta densidade.

Métodos

Neste trabalho será utilizado um banco de dados público aberto (Matran-Fernandez et al. 2019). Esse conjunto de dados contém dados de 13 movimentos do dia-a-dia, como apontar, agarrar, movimento de pinça. Esses movimentos foram realizados por 25 sujeitos, dos quais foram medidas a atividade muscular do músculo flexor radial do carpo, bem como os ângulos de cada uma das articulações dos dedos da mão. A atividade muscular foi medida utilizando EMG de alta densidade (Farina, D e Negro, F, 2012) e os ângulos das articulações são medidos com uma luva com 18 sensores (CyberGlove III, Cyber Glove Systems LLC, San Jose, CA).

Neste projeto a discente deve rever e implementar diferentes métodos de Data Augmentation. Existem diversas técnicas que podem ser utilizadas, como o Synthetic Minority Over-sampling Technique (SMOTE), que faz uma combinação linear entre amostras para gerar um novo dado (Chawla et al. 2002), métodos utilizados com imagens como deslocar e rotacionar as amostras existentes, para gerar uma nova amostra (Shijie et al. 2017), interpolação dos sinais dos eletrodos para ter uma maior quantidade de sinais no tempo (Negro et al. 2016), entre outros métodos. Esses métodos serão escritos em Python para o uso em

dados de HD-EMG. Ao fim, os códigos deverão ser disponibilizados no Github, bem como a sua documentação.

Os testes dos métodos serão realizados em modelos de classificação desenvolvidos pela própria discente em projeto anterior.

Todos os códigos computacionais serão escritos na linguagem de programação Python, uma linguagem de alto nível que possui diversas bibliotecas próprias para computação científica e tem uma ampla comunidade de usuários Perkel (2015). Os códigos produzidos serão disponibilizados de forma aberta na plataforma Github.

Viabilidade

O trabalho proposto não exige nenhum conhecimento prévio diferente do já obtido em disciplinas já cursadas pela candidata, como Processamento da Informação, Fenômenos Mecânicos, Geometria Analítica e Funções de Várias Variáveis. Além disso, a discente está fazendo uma iniciação científica em tema próximo com um excelente desempenho, já conhecendo a linguagem de programação Python que será usada no projeto. Alguns poucos conhecimentos que não foram vistos em nenhuma disciplina já cursada nem que serão cursadas nos próximos quadrimestres poderão ser explicados pelo orientador.

Considerando o equipamento necessário para completar o projeto, um computador simples, que a discente já possui, e computadores localizados no laboratório de Biomecânica são suficientes. Caso eventualmente seja necessário um poder de processamento maior, poderá ser utilizado o Cluster Titânio da UFABC, que já é utilizado pelo orientador.

Considerando isso, o projeto se mostra totalmente exequível no período de 12 meses.

Cronograma

O cronograma do projeto está mostrado na Tabela 1. As tarefas estão descritas com a estimativa do mês em que essa tarefa será executada, contado a partir do início do projeto.

Tabela 1 - Cronograma por mês da execução do projeto.

Tarefas/Mês	1	2	3	4	5	6	7	8	9	10	11	12
Revisão Bibliográfica												
Implementação dos métodos de Data Augmentation												
Uso dos métodos nos dados da base utilizada												
Avaliação dos resultados e implementação de modificações nos métodos												
Relatório final e artigo para congresso												

Referências

CHAWLA, N. V.; BOWYER, K. W.; HALL, L. O.; KEGELMEYER, W. P. SMOTE: Synthetic minority over-sampling technique. **The journal of artificial intelligence research**, v. 16, p. 321–357, 2002. AI Access Foundation.

FARINA, D.; MERLETTI, R.; ENOKA, R. M. The extraction of neural strategies from the surface EMG. **Journal of Applied Physiology**, 2004. Disponível em: <<http://dx.doi.org/10.1152/japplphysiol.01070.2003>>. .

FARINA, D.; NEGRO, F. Accessing the neural drive to muscle and translation to neurorehabilitation technologies. **IEEE reviews in biomedical engineering**, v. 5, p. 3–14, 2012.

FARINA, D.; NEGRO, F.; GAZZONI, M.; ENOKA, R. M. Detecting the unique representation of

motor-unit action potentials in the surface electromyogram. **Journal of neurophysiology**, v. 100, n. 3, p. 1223–1233, 2008.

FARINA, D.; VUJAKLIJA, I.; SARTORI, M.; et al. Man/machine interface based on the discharge timings of spinal motor neurons after targeted muscle reinnervation. **Nature Biomedical Engineering**, 2017. Disponível em: <<http://dx.doi.org/10.1038/s41551-016-0025>>. .

JESINGER, R. A.; STONICK, V. L. Processing signals from surface electrode arrays for noninvasive 3D mapping of muscle activity. **Proceedings of IEEE 6th Digital Signal Processing Workshop**. Disponível em: <<http://dx.doi.org/10.1109/dsp.1994.379868>>. .

KEENAN, K. G.; FARINA, D.; MERLETTI, R.; ENOKA, R. M. Influence of motor unit properties on the size of the simulated evoked surface EMG potential. **Experimental Brain Research**, 2006a. Disponível em: <<http://dx.doi.org/10.1007/s00221-005-0126-7>>. .

KEENAN, K. G.; FARINA, D.; MERLETTI, R.; ENOKA, R. M. Amplitude cancellation reduces the size of motor unit potentials averaged from the surface EMG. **Journal of applied physiology**, v. 100, n. 6, p. 1928–1937, 2006b.

MATRAN-FERNANDEZ, A.; RODRÍGUEZ MARTÍNEZ, I. J.; POLI, R.; CIPRIANI, C.; CITI, L. SEEDS, simultaneous recordings of high-density EMG and finger joint angles during multiple hand movements. **Scientific data**, v. 6, n. 1, p. 186, 2019.

MERLETTI, R.; BOTTER, A.; TROIANO, A.; MERLO, E.; MINETTO, M. A. Technology and instrumentation for detection and conditioning of the surface electromyographic signal: state of the art. **Clinical biomechanics**, v. 24, n. 2, p. 122–134, 2009.

NEGRO, F.; MUCELI, S.; CASTRONOVO, A. M.; HOLOBAR, A.; FARINA, D. Multi-channel intramuscular and surface EMG decomposition by convolutive blind source separation. **Journal of neural engineering**, v. 13, n. 2, p. 026027, 2016.

PERKEL, J. M. Programming: Pick up Python. **Nature**, v. 518, n. 7537, p. 125–126, 2015.

PHINYOMARK, A.; SCHEME, E. EMG Pattern Recognition in the Era of Big Data and Deep Learning. **Big Data and Cognitive Computing**, v. 2, n. 3, p. 21, 2018. Multidisciplinary Digital Publishing Institute. Acesso em: 23/2/2022.

SHIJIE, J.; PING, W.; PEIYI, J.; SIPING, H. Research on data augmentation for image classification based on convolution neural networks. 2017 Chinese Automation Congress (CAC). **Anais...**, 2017. IEEE. Disponível em: <<http://ieeexplore.ieee.org/document/8243510/>>. .

XIONG, D.; ZHANG, D.; ZHAO, X.; ZHAO, Y. Deep learning for EMG-based human-machine interaction: A review. **IEEE/CAA journal of automatica sinica**, v. 8, n. 3, p. 512–533, 2021. Institute of Electrical and Electronics Engineers (IEEE).